

# Análise de Fatores de Risco para Acidente Vascular Cerebral (AVC)

Pesquisa Nacional de Saúde 2019

Iury Mota Santos, [iury.santos@sga.pucminas.br](mailto:iury.santos@sga.pucminas.br)

Thiago Andrade Monteiro, [o.thiagoamonteiro@gmail.com](mailto:o.thiagoamonteiro@gmail.com)

Iago Paiva Faria, [iago.faria.1625316@sga.pucminas.br](mailto:iago.faria.1625316@sga.pucminas.br)

Professor: **Gabriel Fonseca**

*Curso de Ciência de Dados, Instituto de Informática e Ciências Exatas*

Pontifícia Universidade de Minas Gerais (PUC MINAS), Belo Horizonte – MG – Brasil

# Resumo Executivo

O Acidente Vascular Cerebral (AVC), conhecido como derrame, é uma condição neurológica grave causada pela interrupção do fluxo sanguíneo no cérebro, seja por obstrução (isquêmico) ou rompimento de um vaso (hemorrágico). Essa interrupção gera falta de oxigênio e nutrientes, resultando em sequelas motoras, cognitivas ou até óbito.

Globalmente, o AVC está entre as principais causas de morte e incapacidade. No Brasil, é uma das maiores causas de mortalidade, relacionado a fatores como hipertensão, diabetes, tabagismo, sedentarismo e envelhecimento. Além dos impactos individuais, gera elevados custos sociais e econômicos.

Este projeto propõe analisar a PNS 2019 para identificar relações entre variáveis demográficas, clínicas e comportamentais associadas ao AVC. O objetivo é compreender padrões relevantes para a saúde pública e apoiar a conscientização social.

## Sobre a Pesquisa

A Pesquisa Nacional de Saúde (PNS 2019), realizada pelo IBGE e Ministério da Saúde, fornece dados representativos sobre condições de saúde e prevalência de doenças crônicas.

# Introdução e Contextualização

## Foco do Trabalho

Análise do Acidente Vascular Cerebral (AVC) utilizando dados da PNS 2019, identificando fatores de risco e padrões associados à doença através de variáveis demográficas, clínicas e comportamentais.

## Contexto Nacional

O AVC é responsável por cerca de 100 mil mortes anuais no Brasil, gerando custos sociais e econômicos significativos. É uma das principais causas de morte e incapacidade no país.

## Base de Dados

A PNS 2019, realizada pelo IBGE, constitui uma base sólida para análises quantitativas sobre prevalência e fatores de risco, permitindo identificar padrões relevantes na população brasileira.

## Problema e Objetivos

### O Problema

Apesar da elevada incidência do AVC no Brasil, os fatores de risco associados frequentemente não são devidamente identificados ou monitorados pela população, dificultando ações preventivas eficazes. A ausência de análises integradas limita a compreensão dos determinantes dessa condição.

### Objetivo Geral

Desenvolver uma análise baseada na PNS 2019 para investigar quais variáveis demográficas, clínicas e comportamentais estão associadas à ocorrência de AVC, possibilitando a identificação de padrões relevantes para a saúde pública.

**Pergunta Orientada a Dados:** Quais fatores demográficos, clínicos e comportamentais estão mais associados à prevalência de Acidente Vascular Cerebral (AVC) na população brasileira, de acordo com os dados da PNS 2019?

01

### Analisar variáveis demográficas

Investigar a relação entre características demográficas e a ocorrência do AVC

02

### Avaliar fatores de risco

Examinar a influência de fatores clínicos e comportamentais como hipertensão, diabetes, tabagismo e sedentarismo

03

### Construir visualizações

Desenvolver gráficos e tabelas para compreender os padrões identificados nos dados

04

### Desenvolver modelo preditivo

Construir e otimizar modelo utilizando variáveis selecionadas

05

### Avaliar desempenho

Validar métricas do modelo para assegurar análise robusta e interpretável



# Justificativas e Público-Alvo

## Justificativas

O desenvolvimento deste trabalho é motivado pela necessidade de compreender melhor os fatores associados à ocorrência do AVC na população brasileira. A escolha de analisar os dados da PNS 2019 permite explorar uma base confiável e representativa, possibilitando a identificação de padrões demográficos, clínicos e comportamentais relacionados à doença.

A análise contribui para estratégias de prevenção e conscientização em saúde pública, fornecendo insights baseados em evidências para formuladores de políticas e profissionais da saúde.

## Público-Alvo



### Pacientes

Indivíduos diagnosticados com AVC que buscam compreender melhor sua condição



### Grupos de Risco

Idosos, hipertensos, diabéticos, pessoas com histórico familiar de AVC, sedentários e fumantes



### Profissionais da Saúde

Envolvidos no acompanhamento, diagnóstico e reabilitação de pacientes com AVC



### Gestores Públicos

Formuladores de políticas públicas em saúde que necessitam de dados para tomada de decisão

# Análise Exploratória dos Dados

293.726	96,5%	108.525
Amostra Total	Taxa de Resposta	Domicílios
Indivíduos com 15 anos ou mais participantes da pesquisa	Refletindo alta qualidade e confiabilidade dos dados coletados	Distribuídos em 2.000 municípios de todas as unidades da federação


A Pesquisa Nacional de Saúde (PNS) 2019 apresenta representatividade nacional, garantindo a qualidade das análises. Para iniciar o estudo, foi necessário preparar o ambiente e os dados disponíveis através da leitura do layout SAS e carregamento do arquivo de dados em DataFrame do pandas.

## Variáveis e Dicionário

```
dicionario_variaveis = {
    "V0001": "Unidade da Federação (UF)",
    "V0022": "Peso do morador selecionado",
    "V0031": "Região geográfica",
    "V0026": "Situação do domicílio (urbano/rural)",
    "A00601": "Forma como a água chega ao domicílio (canalizada, sem canalização etc.)",
    "Q068": "Diagnóstico médico de AVC (acidente vascular cerebral)",
    "C006": "Sexo do morador (masculino/feminino)",
    "C008": "Idade do morador (em anos)",
    "Q002": "Diagnóstico médico de hipertensão arterial",
    "Q030": "Diagnóstico médico de diabetes",
    "Q060": "Diagnóstico médico de colesterol alto",
    "P050": "Atualmente, o(a) Sr(a) fuma algum produto do tabaco",
    "Q092": "Diagnóstico médico de depressão",
    "W00101": "Peso do morador (em kg)",
    "W00201": "Altura do morador (em cm)",
    "I001": "Autoavaliação do estado de saúde (muito bom, bom, regular etc.)",
    "P035": "Prática de atividade física (tempo semanal)",
    "F00101": "Rendimento domiciliar per capita",
}
```

## Diagrama Conceitual dos Fatores de Risco

O desenho amostral possibilita uma análise detalhada das condições de saúde, do acesso a serviços e dos comportamentos da população. A partir dele, realizamos análise de correlação para medir a força da associação entre fatores e a ocorrência de AVC.

 **Ajuste Metodológico**

Após exploração inicial, identificou-se que algumas variáveis não estavam presentes no conjunto de dados final. Foi necessário realizar ajuste no escopo, removendo variáveis indisponíveis e focando nos dados efetivamente validados.

# Resultados Amostrais e Qualidade dos Dados

A análise da qualidade dos dados revela padrões importantes sobre a cobertura e completude das variáveis. Enquanto algumas possuem cobertura praticamente completa, outras apresentam valores faltantes significativos que devem ser considerados nas análises.

## Dados Ausentes

A análise de dados ausentes revela que algumas variáveis apresentam alta proporção de registros faltantes. Destacam-se como mais problemáticas as variáveis relacionadas a condições de saúde e estilo de vida:

- Diagnóstico médico de problema no coração: 98,39% ausentes
- Altura do indivíduo: 97,77% ausentes
- Peso do indivíduo: 97,76% ausentes

Variáveis demográficas básicas como situação do domicílio, região geográfica e unidade da federação não apresentam registros ausentes, garantindo base consistente para análises agregadas.

## Detecção de Outliers

Foi realizada a detecção de outliers nas principais variáveis numéricas utilizando o método do IQR (Intervalo Interquartil):

Variável	Outliers	Limite Inferior	Limite Superior
Peso do morador	4.457	0.00	8.00
Altura (cm)	21	135.70	192.50
Idade (anos)	7	-35.50	104.50
Atividade física	0	-2.50	9.50



# Análise de Correlações e Padrões

O algoritmo calcula a correlação de todas as variáveis numéricas com a variável alvo AVC, substituindo códigos pelos respectivos nomes e classificando como positiva ou negativa.

## Desafio Metodológico: Correlação de Pearson

A primeira abordagem utilizou correlação linear de Pearson, mas o resultado indicou correlação negativa contraintuitiva, sugerindo que o aumento da idade estaria associado a menor ocorrência de AVC.

Para superar essa limitação, optou-se pelo teste **Qui-Quadrado** de independência, ideal para verificar associação entre variáveis categóricas, tratando cada faixa etária como categoria distinta.

### Validação Estatística

O teste Qui-Quadrado confirma que existe associação estatisticamente significativa entre faixa etária e diagnóstico de AVC, validando a hipótese inicial de que as variáveis estão relacionadas.

## Evidência Visual: Idade e AVC

O gráfico serve como evidência visual definitiva que corrobora o teste Qui-Quadrado, demonstrando que o risco aumenta progressivamente com o envelhecimento.

## Padrões Contraintuitivos e Fatores de Confusão

### Atividade Física

Demonstrou aparente correlação positiva com AVC. Isso ocorre porque pessoas idosas ou aposentadas, com risco naturalmente elevado, frequentemente mantêm ritmo de atividade física maior.

### Tabagismo

Indivíduos que fumam menos apresentam maior incidência de AVC nos dados. Pessoas mais velhas têm maior risco e muitos deixam de fumar por questões de saúde.

### Depressão

Aparece fortemente associada ao AVC. Parte é real, mas outra é explicada pela idade: pessoas idosas tendem a apresentar tanto mais AVC quanto mais diagnósticos de depressão.

# Indução de Modelos Preditivos

## Modelo 1: K-Nearest Neighbors (KNN)

O KNN é um algoritmo supervisionado baseado na similaridade entre observações. Sua premissa é que instâncias próximas no espaço de características tendem a pertencer à mesma classe.

Para preparação dos dados, realizou-se normalização das variáveis numéricas e aplicou-se SMOTE para balancear as classes da variável target, devido à forte desproporção entre indivíduos com e sem diagnóstico de AVC.



O modelo KNN apresentou desempenho superior após balanceamento, conseguindo diferenciar adequadamente indivíduos com e sem histórico de AVC. O bom desempenho está relacionado à capacidade do KNN de capturar padrões locais e relações não lineares nos dados.

## Modelo 2: Regressão Logística

A Regressão Logística é um método estatístico de classificação que estima a probabilidade de uma instância pertencer a uma classe. Funciona ajustando uma função sigmoide que transforma valores previstos em probabilidades entre 0 e 1.

Os resultados mostraram bom desempenho geral na capacidade de prever casos de AVC, com métricas de precisão e recall equilibradas.

### Vantagem Interpretativa

A Regressão Logística fornece forma de interpretar a influência de cada variável no desfecho. Cada coeficiente indica o quanto uma variável aumenta ou diminui a probabilidade de AVC, permitindo compreender quais fatores têm maior impacto.

## Modelo 3: Rede Neural (MLP)

A Rede Neural Multi-Layer Perceptron (MLP) é capaz de aprender padrões complexos e não lineares através de múltiplas camadas de neurônios conectadas. Foram testadas duas versões: sem e com SMOTE.

1	2
<h3>MLP sem SMOTE</h3> <p>Acurácia de 97,8%, mas recall muito baixo para classe minoritária (AVC). O modelo aprendeu a classificar indivíduos sem AVC, mas praticamente ignorou casos positivos.</p>	<h3>MLP com SMOTE</h3> <p>Acurácia de 92,4%, com melhora no recall da classe minoritária. O balanceamento permitiu que a MLP aprendesse padrões de AVC, aumentando recall de 0% para 22%.</p>